Projet final : Caractérisation des bandes riveraines à partir de données LiDAR

GLO-4030

Apprentissage par réseaux de neurones profonds

Par

Corinne Dumais (111 263 065)

Rapport présenté à

Philippe Giguère

Hiver 2023

Résumé :

La caractérisation de la qualité des bandes riveraines au Québec est essentielle pour bien planifier la préservation des milieux hydriques et limiter l'impact des activités humaines et agricoles sur la santé des écosystèmes fluviaux. L'indice présentement utilisé étant basé sur une estimation visuelle peu précise, ce projet a eu comme objectif de fournir une méthode de segmentation automatique par apprentissage profond avec un U-Net qui utilise des données LiDAR. L'impact de l'ajout d'attention a été évalué, de même que l'impact de l'augmentation de données. Les performances finales obtenues ont été de 82% de coefficient Dice et 74% d'exactitude. L'apprentissage profond offre donc une solution prometteuse pour estimer la couverture de sol autour des bandes riveraines à partir des données LiDAR.

Table des matières

1 Introduction **1**

2 Méthodologie **2**
2.1 Jeu de données 2
2.2 Architecture 4
2.3 Entraînements et expérimentations 5

3 Résultats **6**
3.1 Courbes d'entraînement 6
3.2 Matrice de confusion 7
3.3 Prédiction sur des fermes 7

4 Analyse **8**

5 Conclusion **9**

1 Introduction

Au Québec, 11% du territoire est occupé par des milieux humides et hydriques [1], ce qui inclut de nombreuses rivières. La protection de ce type de milieu est primordial, que ce soit parce que l'eau qui s'y trouve est potable, parce que des nappes souterraines s'y alimentent ou pour la préservation de la faune et la flore. Ainsi, non seulement les propriétaires riverains sont dans l'obligation de maintenir une bande de végétation de long des cours d'eau, mais de bonnes bandes riveraines peuvent contribuer à diminuer l'impact des activités agricoles sur l'environnement [2]. En ce sens, la quantification de la qualité des bandes riveraines est essentielle, car elle permet aux gestionnaires de bassins versants d'évaluer la condition de l'habitat riverain pour prévenir de potentiels impacts sur l'intégrité des milieux aquatiques. Au Québec, l'indice utilisé est l'indice de qualité des bandes riveraines (IQBR), qui se base sur une estimation visuelle sur des tronçons de 500 mètres. Cet indice est une somme de la proportion des classes d'occupation du sol présentes pondérées par des coefficients prédéterminés [3].

Il serait donc avantageux de se doter d'une méthode automatique pour évaluer plus précisément l'occupation du sol dans les régions de bandes riveraines, particulièrement à partir de données publiques qui couvrent l'ensemble du Québec comme les données LIDAR [4]. L'objectif de ce projet est donc d'utiliser l'apprentissage profond pour implémenter un algorithme de segmentation sémantique à partir des données LIDAR. Un réseau U-Net implémenté avec PyTorch sera utilisé pour cette tâche. À la suite de cette introduction, le jeu de données utilisé sera présenté, suivi de la méthodologie, des résultats obtenus et d'une analyse avant de conclure.

2 Méthodologie

2.1 Jeu de données

Le jeu de données est composé d'un total de 41 fermes qui proviennent de 5 bassins versants différents au Québec. Des fermes de validation sont sélectionnées pour chaque bassin versant et le reste des données est utilisé pour l'entraînement. Dans une étape subséquente à ce projet, on aurait également des fermes supplémentaires pour constituer un ensemble de test. Le tableau 1 présente le nombre de fermes par bassin versant et la répartition du jeu de donnée pour l'entraînement et la validation.

TABLE 1 – Division du jeu de données

Bassin versant	Nb fermes d'entraînement	Nb fermes de validation	Total
Châteauguay	6	1	7
Chaudière	6	2	9
Richelieu	5	1	6
Ticouape	8	2	10
Yamaska	8	2	10
Total	33	8	41

Les données d'entraînement ont trois bandes : le modèle de hauteur de la canopée (MHC), le modèle numérique de terrain (MNT) et l'index topographique d'humidité (TWI). Les valeurs de ces bandes ont été acquises via des données LIDAR rendues accessibles publiquement par le Gouvernement du Québec [4]. Le valeurs de MHC et TWI sont normalisées par rapport à l'ensemble du jeu de données. Les valeurs de MNT, elles sont normalisées par image puisqu'il est plus pertinent d'avoir une mesure de la variation de la hauteur du terrain au sein d'une même région plutôt qu'en comparaison avec d'autres régions. En effet, le MNT étant mesuré par rapport au niveau de la mer, deux fermes éloignées peuvent avoir des valeurs moyennes complètement différentes, mais sans que ça affecte la façon dont l'occupation du sol sera classifiée. La Figure 1 présente un exemple des 3 bandes et de la vérité terrain pour l'une des fermes du jeu de données.

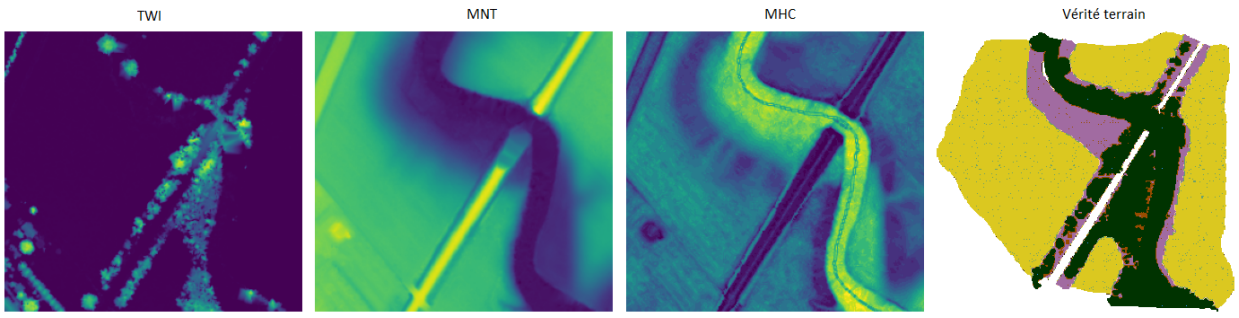


FIGURE 1 – Exemple de données d'entraînement

La classification est faite en 6 classes : forêt, arbustaie, herbacée, pâturage/culture, sol nu et autres (coupe forestière, sol nu, socle rocheux, infrastructure). Les vérités terrains ont déjà été faites par des membres du Laboratoire de télédétection environnementale et nordique de l'Institut national de la recherche scientifique. Pour faire la classification des pixels, des images drône RGB des régions ciblées ont été acquises, puis une segmentation orientée-objet a été appliquée et chacun des objet obtenu a été classé manuellement par un utilisateur expérimenté. La vérité terrain a été faite pour des polygones dont le contour est irrégulier.

Initialement, les données étaient supposément annotées avec 10 classes en plus des valeurs 'no data' qui ont la valeur 255, mais quelques modifications ont été apportées pour permettre une bonne convergence de l'entraînement :

1. Les pixels classés comme infrastructure et eau (classes 9 et 10) ont des valeurs fausses de MHC, MNT et TWI, donc ces pixels se voient attribuer la classe 0, qui sera ignoré lors du calcul de la fonction de perte.
2. Il n'y a pas de pixel de classe socle rocheux (classe 8), donc cette catégorie est ignorée.
3. Les classes culture et pâturage étaient 2 classes distinctes, mais il n'y a pas suffisamment de différence dans les bandes pour permettre au modèle de les distinguer (même hauteur, même humidité). Ces deux classes sont donc regroupées dans la classe 5 et le sol nu est attribué à la classe 6.
4. Les 'no data' sont également renommés comme faisant partie de la classe 0. En effet, cela permettra d'utiliser les imagettes en bordure des polygones de vérité terrain tout en ignorant les pixels non-annotés.

La légende des couleurs est présentée dans la Figure 2. Ainsi, malgré que l'IQBR nécessite

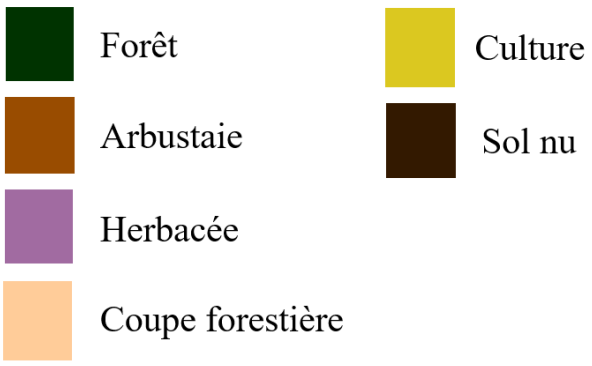


FIGURE 2 – Légende des couleurs pour l'occupation du sol

normalement 10 classes, le jeu de données n'est pas assez complet pour prédire toutes ces classes. Une autre caractéristique problématique du jeu de données est que la présence des classes n'est pas balancée. Des solutions à ce problème seront présentés plus loin. Le tableau 2 présente le pourcentage de chaque classe.

Classe	Proportion des pixels d'entraînement
Autre (0)	7.3%
Forêt (1)	18.9%
Arbustaie (2)	6.6%
Herbacée (3)	14.2%
Coupe forestière (4)	0.1%
Pâturage/culture (5)	52.2%
Sol nu (6)	0.7%

TABLE 2 – Pourcentage de présence de chaque classe dans les données d'entraînement

2.2 Architecture

L'architecture utilisée est un U-Net [5]. Ce type de réseau a une partie descendante (encodeur) qui réduit la résolution spatiale de l'image en extrayant les caractéristiques et une partie ascendante (décodeur) qui restaure la résolution spatiale en produisant une carte de segmentation pixel par pixel. Les deux parties sont reliées par des connexions résiduelles qui permettent au réseau de conserver les informations de l'image d'origine à différents niveaux de résolution. L'encodeur et le décodeur ont chacun 4 blocs de deux couches de convolution et sont reliés par un bottleneck de deux couches également. Des noyaux de convolution de dimension 3x3 sont utilisés dans les blocs. Il y a une couche de *batchnorm* après chaque couche de convolution (avant l'activation ReLU). L'optimiseur utilisé est Adam [6].

Puisque les images ont chacune des dimensions de l'ordre des milliers de pixels, chaque image est séparée en tuiles de 32x32 pixels de façon à pouvoir entraîner le réseau sur des données d'entrée dont la taille est plus raisonnable. Ce type de pratique est commune dans le traitement d'images satellites. La taille des données d'entrée sera donc 32x32x3 puisque 3 bandes sont utilisées (MHC, MNT, TWI). Pour les prédictions sur une ferme complète, l'image d'entrée est divisée en imagettes de 32x32 pixels, l'inférence est effectuée sur chaque imagette, puis l'image est reconstruite.

Une architecture modifiée de U-Net avec de l'attention [7] sera également utilisée pour comparer avec l'architecture standard. L'architecture reste très similaire, mais des portes d'attention sont ajoutées avant la concaténation des caractéristiques extraites par l'encodeur avec celles du décodeur.

La fonction de coût utilisée est une fonction de perte qui correspond à

$$Loss = 1 - \text{Cofficient Dice}$$

C'est une mesure similaire au F1-Score qui pénalise davantage que la crossentropie pour les faux négatifs. Ce type de métrique et son adaptation pour en faire une fonction de coût permet de palier, en partie, au problème de déséquilibre des classes dans le jeu de données.

2.3 Entraînements et expérimentations

Les entraînements ont été effectués avec un GPU NVIDIA Quadro T1000. Tout d'abord, puisque le jeu de données est limité, on applique de l'augmentation de données aux données d'entraînement avec des rotations à 90°, 180° et 270°. Grâce à cela, on multiplie par un facteur 4 la quantité de données d'entraînement. L'entraînement est configuré pour conserver les poids de l'epoch qui a obtenu la perte la plus basse en validation. Les hyperparamètres sont résumés dans le Tableau 3.

Hyperparamètre	U-Net standard	U-Net avec attention
Batch size	256	256
Learning rate	1e-4	1e-4
Channels	32	32
Epochs	35	35

TABLE 3 – Hyperparamètres avec et sans attention

Un entraînement du modèle avec attention est également effectué sans l'augmentation des données pour en évaluer l'impact. Tous les autres paramètres sont laissés tels que présentés ci-dessus.

Finalement, un dernier modèle est entraîné avec un augmentation des données qui incluent également des réflexions horizontales et verticales afin de voir s'il est possible d'atténuer encore plus la problématique de sur-entraînement.

3 Résultats

3.1 Courbes d'entraînement

La Figure 3 présente les courbes de loss, accuracy et Dice pour des entraînements avec et sans attention.

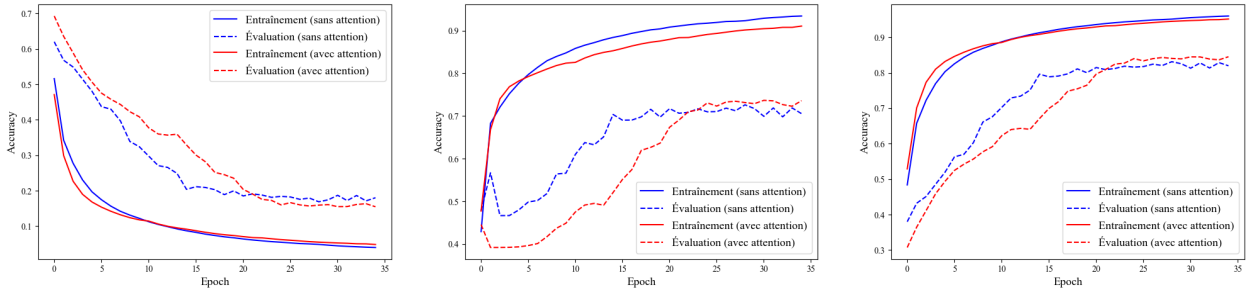


FIGURE 3 – Comparaison de l'entraînement avec et sans attention

Pour le modèle avec de l'attention, L'évaluation sur le jeu de données d'entraînement donne un coefficient Dice de 0.95 et une exactitude de 0.90. L'évaluation sur les données de validation donne un coefficient Dice de 0.82 et une exactitude de 0.74.

En gardant le modèle avec attention et en retirant l'augmentation des données qui avaient été ajoutée, on obtient les courbes de perte présentée à la Figure 4.

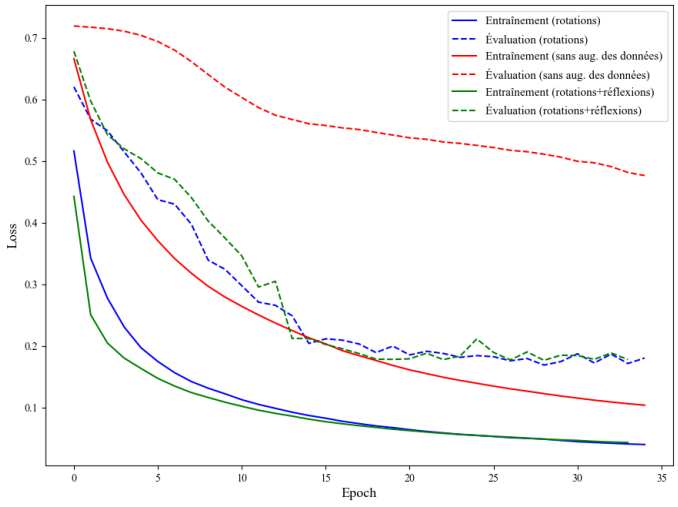


FIGURE 4 – Effet de l'augmentation des données sur le modèle avec attention

3.2 Matrice de confusion

La Figure 5 montre la matrice de confusion obtenue sur l'ensemble de validation.

		Prédictions							
		0	**1**	**2**	**3**	**4**	**5**	**6**	Erreur ommission
Vérité	**0**	19,94	1,53	0,69	1,30	0,00	0,34	0,05	3,91
	1	0,88	12,54	1,19	0,96	0,00	0,62	0,06	3,71
	2	0,27	0,42	0,86	0,12	0,00	0,27	0,00	1,07
	3	1,27	1,16	1,41	4,29	0,00	3,07	0,10	7,00
	4	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
	5	3,27	1,22	1,01	4,03	0,02	36,53	0,57	10,13
	6	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
	Erreur commission	5,68	4,34	4,29	6,41	0,02	4,29	0,79	74,17

FIGURE 5 – Matrice de confusion (en pourcentages) de la classification des pixels des données d'entraînement

3.3 Prédiction sur des fermes

La Figure 6 montre des prédictions sur deux fermes complètes, ainsi que la vérité terrain à titre de comparaison et les données passées en entrée pour obtenir le résultat.

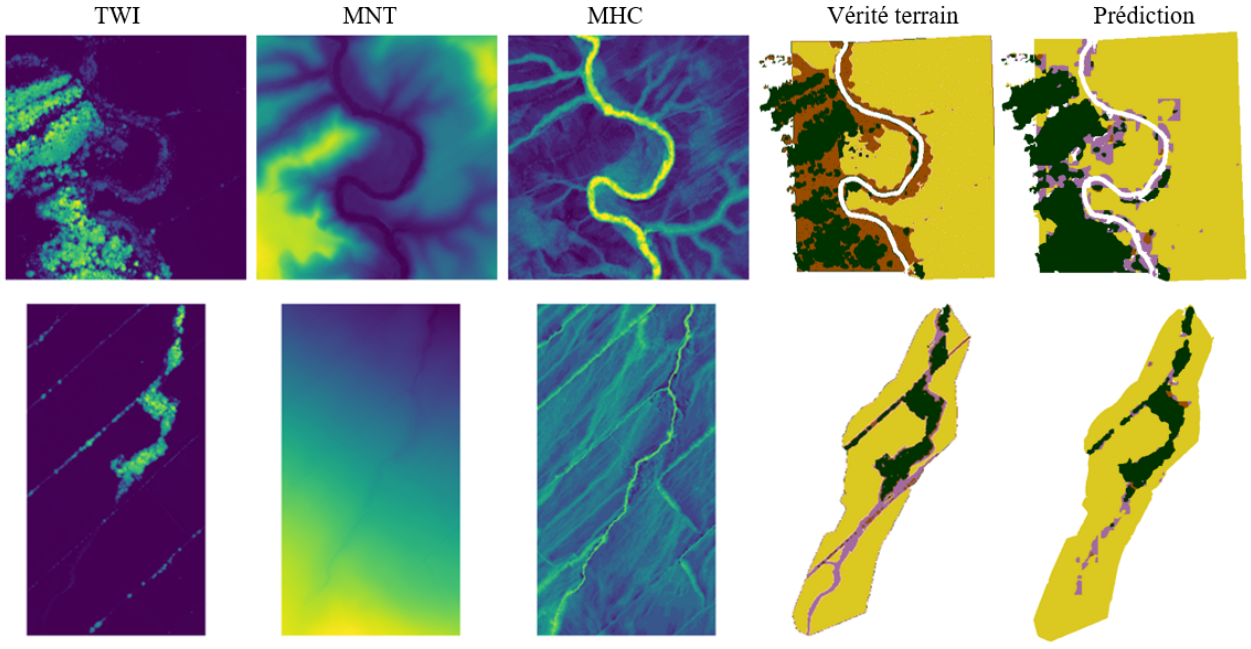


FIGURE 6 – Résultats sur deux fermes d'évaluation

4 Analyse

La Figure 3 montre que l'ajout d'attention n'a pas un impact très significatif, mais permet quand même de réduire légèrement le sur-apprentissage. Ainsi, le modèle avec attention a été conservé pour la suite des manipulations. Probablement que l'attention a peu d'impact pour notre application puisqu'on ne cherche pas à segmenter un objet précis dans l'image et que l'idée de porter plus attention à certaines portions de l'image a moins de sens dans ce cas.

Avec un Dice de 95% en entraînement et 82% en validation, le modèle souffre de su-entraînement. Ce problème n'a pas réussi a être régler, malgré de nombreux essais avec l'ajout de régularisation L2. L'hypothèque qu'ajouter encore plus d'augmentation des données avec les réflexions allaient aider à régler ce problème s'est avérée fausse, comme le montre la Figure 4. En effet, à part pour la variabilité entre les entraînements, l'ajout des réflexions ne change pas les performances par rapport à juste les rotations. Toutefois, la Figure 4 montre que l'augmentation des données avec les rotations a été bénéfique puisque cela a permis d'obtenir de meilleures performances sur les jeux d'entraînement et de validation, ainsi que de diminuer le sur-apprentissage.

L'exactitude obtenue sur les données de validation est de 74%, ce qui est détaillé dans la matrice de confusion de la Figure 5. On y voit les erreurs de commission et d'omission. Les erreurs sur la classe 0 sont moins intéressantes puisqu'on l'écarte du calcul de la fonction de coût. Ainsi, c'est la confusion entre les classes 3 et 5 qui semble le plus coûteuse. Ce sont respectivement les classes herbacées et culture/pâturage. Il est possible que la distinction entre les deux en terme de hauteur soit ambiguë. Pour l'ensemble des classes, c'est également probable qu'il y ait des erreurs d'annotations puisqu'il est très complexe de tout annoter parfaitement à partir d'images de drônes. Finalement, la classe Arbustaie (2) semble souvent être classée erronément comme de la Forêt (1) ou Herbacée (3). Encore une fois, ce problème peut venir du fait que ces classes ont des attributs similaires. Dans les cas des arbustaies, ils sont parfois très étroits et il est possiblement que le capteur LiDAR ait extrait la hauteur juste à côté. La matrice de confusion illustre également qu'il y avait trop peu de coupe forestière et de sol nu dans les données pour bien entraîner sur ses classes et évaluer la performance de façon fiable.

Malgré les problèmes et sources d'erreurs mentionnées ci-haut, les résultats de la Figure 6 sont visuellement assez satisfaisant. On voit d'ailleurs dans les bandes que la différence entre ce qui est classé comme culture, herbacée ou arbustaie est parfois imperceptible. Cela indique qu'il faudrait davantage de sources d'informations/bandes pour faire une classification plus complexe.

Toutefois, puisque la méthode actuelle de calcul de l'IQBR est manuelle et très imprécise, même une performance de 74% permet d'avoir un nouvel outil intéressant pour les analyses.

5 Conclusion

En conclusion, l'objectif d'obtenir un modèle de segmentation automatique des bandes riveraines a été atteint. La performance de ce modèle étant 82% pour le Dice et 74% pour l'exactitude, on peut également conclure que cette solution est plus performante que l'estimation visuelle. Le programme effectue également un traitement rapide et peu coûteux puisqu'il est basé sur des données disponibles gratuitement. Il serait intéressant de refaire le projet avec davantage de bandes dans l'éventualité où des données optiques couvriraient le Québec au complet. Avec du RGB, on pourrait utiliser toute la puissance CNN pour utiliser la couleur et la texture en plus du MHC, MNT et TWI.

Références

[1] Gouvernement du Québec. URL : https://www.environnement.gouv.qc.ca/eau/rives/milieuxhumides.htm.

[2] Gouvernement du Québec. URL : https://www.environnement.gouv.qc.ca/eau/flrivlac/bandes-riv.htm.

[3] Gouvernement du Québec. URL : https://www.environnement.gouv.qc.ca/eau/eco_aqua/IQBR/protocole.htm.

[4] Gouvernement du Québec. fr. URL : https://www.donneesquebec.ca/recherche/dataset/produits-derives-de-base-du-lidar.

[5] Olaf Ronneberger, Philipp Fischer et Thomas Brox. "U-Net : Convolutional Networks for Biomedical Image Segmentation". en. In : *arXiv :1505.04597 [cs]* (mai 2015). arXiv : 1505.04597. URL : http://arxiv.org/abs/1505.04597.

[6] Diederik P. Kingma et Jimmy Ba. "Adam : A Method for Stochastic Optimization". en. In : *arXiv :1412.6980 [cs]* (jan. 2017). arXiv : 1412.6980. URL : http://arxiv.org/abs/1412.6980.

[7] Ozan Oktay et al. "Attention U-Net : Learning Where to Look for the Pancreas". en. In : arXiv :1804.03999 (mai 2018). arXiv :1804.03999 [cs]. URL : http://arxiv.org/abs/1804.03999.